

Series temporales, práctica 1: conjunto de datos meteorológicos de Granada-aeropuerto Chauchina medidos por AEMET.

Carlos Manuel Sequí Sánchez

Problema 2. ¿Qué valores de temperatura máxima, a escala diaria, se espera para la primera semana de Marzo de 2018?

Primeramente leemos el conjunto de datos que contiene los siguientes atributos:

- Columna 1 : Identificador Estación
- Columna 2 : Fecha
- Columna 3 : Temperatura Máxima (°C)
- Columna 4 : Hora Temperatura Máxima
- Columna 5 : Temperatura mínima (°C)
- Columna 6 : Hora Temperatura mínima
- Columna 7 : Temperatura Media (°C)
- Columna 8 : Racha máxima de viento (Km/h)
- Columna 9 : Hora de Racha Máxima
- Columna 10 : Velocidad media de Viento (Km/h)
- Columna 11 : Hora de Velocidad Máxima de viento
- Columna 12 : Precipitacion Total diaria (mm)
- Columna 13 : Precipitacion de 0 a 6 horas (mm)
- Columna 14 : Precipitacion de 6 a 12 horas (mm)
- Columna 15 : Precipitacion de 12 a 18 horas (mm)
- Columna 16 : Precipitacion de 18 a 24 horas (mm)

Librerías...

```
library(tseries)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

```
library(lubridate)
```

```
##
## Attaching package: 'lubridate'

## The following object is masked from 'package:base':
##
##   date
```

```
library(imputeTS)
```

```
##
## Attaching package: 'imputeTS'
## The following object is masked from 'package:tseries':
##
##      na.remove
```

Leemos el dataset y, como solo nos interesa la fecha y la temperatura máxima nos quedamos con tan solo esos datos.

```
datos = read.csv("5530E.csv", header = TRUE, sep=";")
datos = datos[,c("Fecha", "Tmax")]
datos$Fecha = as.Date(datos$Fecha)
```

Veamos los valores NA...

```
apply(datos, 2, function(atributo){sum(is.na(atributo))})
```

```
## Fecha Tmax
##      0   124
```


Imputamos valores mediante interpolación en las temperaturas máximas donde existan valores perdidos con el fin de no tergiversar los datos eliminando días del año.

```
datos$Tmax = na.interpolation(datos$Tmax)
```

Obtenemos ahora la cantidad de datos a predecir y la serie temporal en sí

```
Npred = 7 # cantidad de datos a predecir (temperaturas máximas de marzo y abril)
serie = datos$Tmax
serie.ts = ts(serie, frequency = 365) # frequency set to 12 to set stationarity each 12 months
plot(decompose(serie.ts))
```

Decomposition of additive time series




Observamos en la gráfica:

- los valores de la serie
- la tendencia calculada mediante filtros
- la estacionalidad repetida cada 12 instantes de tiempo
- lo que queda de la serie al eliminar tendencia y estacionalidad

Probamos, como hemos hecho en experimentos anteriores, a realizar una transformación logarítmica de la serie para reducir la varianza y así evitar problemas con el cálculo de la estacionariedad:

```
serie.ts.log = log(serie.ts)
serie.log = log(serie)
plot(decompose(serie.ts.log))
```

Decomposition of additive time series



El cambio es relativamente muy pequeño, es posible que tenga mucho que ver la gran cantidad de datos, siendo difícil distinguir la variación entre la gráfica anterior y esta. Aún así, por precaución, tomaremos esta serie por válida.

Observamos los datos de estacionalidad que nos servirán en el futuro para eliminársela a la serie temporal.

```
head(decompose(serie.ts.log)$seasonal)
```

```
## Time Series:
## Start = c(1, 1)
## End = c(1, 6)
## Frequency = 365
## [1] 0.1797105 0.2053683 0.1774451 0.1648794 0.1722653 0.2133311
```

Por simplicidad en el uso de la nomenclatura utilizare la variable serie en lugar de serie.log


```
serie = serie.log
```

Calculamos los instantes de tiempo de la serie

```
# para train
tiempo = 1:length(serie.ts.log)
# para test
tiempoTs = (tiempo[length(tiempo)]+1):(tiempo[length(tiempo)]+Npred)
```

Representamos la serie

```
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
```



Modelamos la tendencia, la cual podemos aparentemente ajustarla de forma lineal, sabiendo que:

$\text{serie} = \text{parametroA} * \text{tiempo} + \text{parametroB}$

Con ayuda de la función `lm` calculamos dichos parámetros:

```
parametros.H1 = lm(serie ~ tiempo)
parametros.H1
```


```
##
## Call:
## lm(formula = serie ~ tiempo)
##
## Coefficients:
## (Intercept)      tiempo
##  3.209e+00   -4.589e-05
```

Tomamos Intercept como termino independiente (`parametroB`) y el otro como el que multiplica al tiempo para poder calcular la serie (`parametroA`). Para modelar la tendencia usamos la fórmula descrita antes:

```
# tendencia estimada para los datos de train
tendEstimadaTr = parametros.H1$coefficients[1] + tiempo*parametros.H1$coefficients[2]
# tendencia estimada para las predicciones de test
tendEstimadaTs = parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2]
```

Comprobamos visualmente si la tendencia se ajusta al modelo que tenemos de la serie temporal:

```
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")
```



Podemos observar los ajustes tanto de la tendencia para los datos de train como de la estimada para los datos de test.

A continuación procedemos a validar de forma estadística que el modelo lineal creado sea correcto. Con el test de Jarque Bera comprobamos si los errores siguen una distribución normal a lo largo del tiempo.

```
JB = jarque.bera.test(parametros.H1$residuals)
JB
```

```
##
##  Jarque Bera Test
##
## data:  parametros.H1$residuals
## X-squared = 102.63, df = 2, p-value < 2.2e-16
```

Como el valor del p-value es inferior a 0.05, no podemos asegurar que los residuos no guarden una diferencia significativa con los datos de una distribución normal, por lo que procedemos a intentar ajustar la tendencia con otro modelo, esta vez cuadrático.


```
# calculo de parámetros
parametros.H1 = lm(serie ~ tiempo + I(tiempo^2))
parametros.H1
```

```
##
## Call:
## lm(formula = serie ~ tiempo + I(tiempo^2))
##
## Coefficients:
## (Intercept)      tiempo  I(tiempo^2)
```

```
##    3.199e+00    -9.575e-06    -2.069e-08
# tendencia estimada para los datos de train
tendEstimadaTr = parametros.H1$coefficients[1] + tiempo*parametros.H1$coefficients[2] + tiempo*parametros.H1$coefficients[3]
# tendencia estimada para las predicciones de test
tendEstimadaTs = parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2] + tiempoTs*parametros.H1$coefficients[3]
```

Comprobamos visualmente si la tendencia se ajusta al modelo que tenemos de la serie temporal:

```
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")
```



Validamos de forma estadística de nuevo con el test de Jarque Bera, con el que comprobamos si los errores siguen una distribución normal a lo largo del tiempo.

```
JB = jarque.bera.test(parametros.H1$residuals)
JB
```

```
##
## Jarque Bera Test
##
## data: parametros.H1$residuals
## X-squared = 102.26, df = 2, p-value < 2.2e-16
```

Una vez más, no logramos modelar la tendencia de manera correcta, veamos como se comporta con una transformación logarítmica:


```

# calculo de parametros
parametros.H1 = lm(serie ~ log(tiempo))

# tendencia estimada para los datos de train
tendEstimadaTr = parametros.H1$coefficients[1] + tiempo*parametros.H1$coefficients[2]
# tendencia estimada para las predicciones de test
tendEstimadaTs = parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2]

# representacion de la tendencia sobre la serie
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")

```



```

# test de normalizacion Jarque Bera
JB = jarque.bera.test(parametros.H1$residuals)
JB

##
##  Jarque Bera Test
##
## data:  parametros.H1$residuals
## X-squared = 99.71, df = 2, p-value < 2.2e-16

```

Como última prueba de transformaciones matemáticas aplicadas para modelar la tendencia de la serie, procedo a intentarlo con una sinusoidal:



```

# calculo de parametros
parametros.H1 = lm(serie ~ sin(tiempo))

# tendencia estimada para los datos de train
tendEstimadaTr = parametros.H1$coefficients[1] + tiempo*parametros.H1$coefficients[2]
# tendencia estimada para las predicciones de test
tendEstimadaTs = parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2]

# representacion de la tendencia sobre la serie
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")

```



```

# test de normalizacion Jarque Bera
JB = jarque.bera.test(parametros.H1$residuals)
JB

##
##  Jarque Bera Test
##
## data:  parametros.H1$residuals
## X-squared = 106.92, df = 2, p-value < 2.2e-16

```

Tras probar con estos distintos modelos obtenidos mediante diferentes transformaciones matemáticas, me decido por realizar diferenciación tantas veces como sea necesario con tal de suavizar la tendencia:

Probamos de nuevo...


```

serie2=diff(serie, differences = 3)
tiempo2= 1:length(serie2)
# calculo de parametros
parametros.H1 = lm(serie2 ~ tiempo2)

# tendencia estimada para los datos de train
tendEstimadaTr = parametros.H1$coefficients[1] + tiempo2*parametros.H1$coefficients[2]
# tendencia estimada para las predicciones de test
tendEstimadaTs = parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2]

# representacion de la tendencia sobre la serie
plot.ts(serie2, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo2, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")

```



```

# test de normalizacion Jarque Bera
JB = jarque.bera.test(parametros.H1$residuals)
JB

##
##  Jarque Bera Test
##
## data:  parametros.H1$residuals
## X-squared = 7374.5, df = 2, p-value < 2.2e-16

```

Como podemos observar, tras las pruebas de modelado de tendencia tanto con diversas transformaciones matemáticas (logarítmica, cuadrática, senoidal) como por diferenciación de la serie con el fin de suavizar la

tendencia, no logramos que los residuos de las diversas tendencias calculadas pasen el test de Jarque Bera, por lo que es posible con alta probabilidad que dichos residuos no sigan una distribución normal. Conociendo este dato, es posible que no haya conseguido modelar la tendencia con ninguno de los modelos obtenidos, por tanto me decido por no restársela a la serie en los siguientes pasos de este ejercicio.


Tras este extenso estudio de la tendencia, procedemos a hayar y eliminar la estacionalidad de la seria:

```
k = 365 # aquí guardamos los datos estacionales
estacionalidad = decompose(serie.ts.log)$seasonal[1:k]
# eliminamos la estacionalidad
serie.sinEst = serie - estacionalidad
```

```
## Warning in serie - estacionalidad: longitud de objeto mayor no es múltiplo
## de la longitud de uno menor
```

Comprobamos como se queda la serie sin dicha estacionalidad


```
plot.ts(serie.sinEst, xlim=c(1, tiempoTs[length(tiempoTs)]))
```



Ahora que tan solo nos queda la componente irregular tras haber eliminado la componente de estacionalidad, procedemos a comprobar si la serie es estacionaria o no mediante el test ACF.

```
acf(serie.sinEst)
```

Series serie.sinEst



Observando este gráfico acf, puede caber la posibilidad de tomar como “bajada lenta” de los datos con respecto a los instantes sucesivos de tiempo, para asegurarnos de la estacionariedad de la serie, procedemos a realizar el test de Dickey-Fuller aumentado:

```
adf.test(serie.sinEst)
```

```
## Warning in adf.test(serie.sinEst): p-value smaller than printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: serie.sinEst
```

```
## Dickey-Fuller = -10.378, Lag order = 12, p-value = 0.01
```


```
## alternative hypothesis: stationary
```

Al tomar como hipótesis nula que la serie es estacionaria y al ser el p-value inferior a 0.05, podemos asegurar con un 95% de probabilidad que la serie es estacionaria, por tanto la tomamos así. Debido a esto no será necesario realizar diferenciación para convertir la serie en estacionaria.

Observamos el acf parcial para ver como influyen de forma individual cada uno de los instantes de tiempo sobre el instante actual.

```
pacf(serie.sinEst)
```

Series serie.sinEst



Observando los gráficos ofrecidos por acf y pacf, y sabiendo que la serie es estacionaria gracias al test de Dickey-Fuller, me resulta coherente pensar en un modelo de medias móviles de grado 5 para modelar la serie temporal mediante ARIMA. La elección del modelo es debido a que en pacf existe una bajada en los datos drástica y una estabilización en forma de ‘olas’, escogiendo el grado del modelo con ayuda del ultimo de los datos que traspasan de forma clara el umbral mínimo en el gráfico acf. Entrenamos el modelo escogido a continuación:

```
# coeficiente de autoregresión = 0, diferenciaciones = 0, coeficiente de medias moviles = 0
modelo = arima(serie.sinEst, order = c(0,0,5))
# calculamos las predicciones
predicciones = predict(modelo, n.ahead = Npred)
valoresPredichos = predicciones$pred
valoresPredichos
```

```
## Time Series:
## Start = 1755
## End = 1761
## Frequency = 1
## [1] 3.277692 3.248398 3.205088 3.179500 3.174752 3.166149 3.166149
```

Observamos ahora de forma visual el modelo incluyendo la serie sin estacionalidad:

```
plot.ts(serie.sinEst, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempoTs,valoresPredichos, col="green")
```

