Series temporales, práctica 1: conjunto de datos meteorológicos de Granada-aeropuerto Chauchina medidos por AEMET.

Carlos Manuel Sequí Sánchez

Problema 1. ¿Qué valores de temperatura máxima, a escala mensual, se espera que tengan los meses de Marzo y de Abril de 2018?

Primeramente leemos el conjunto de datos que contiene los siguientes atributos:
- Columna 1 : Identificador Estación
- Columna 2 : Fecha
- Columna 3 : Temperatura Máxima (ºC)
- Columna 4 : Hora Temperatura Máxima
- Columna 5 : Temperatura mínima (ºC)
- Columna 6 : Hora Temperatura mínima
- Columna 7 : Temperatura Media (ºC)
- Columna 8 : Racha máxima de viento (Km/h)
- Columna 9 : Hora de Racha Máxima
- Columna 10 : Velocidad media de Viento (Km/h)
- Columna 11 : Hora de Velocidad Máxima de viento
- Columna 12 : Precipitacion Total diaria (mm)
- Columna 13 : Precipitacion de 0 a 6 horas (mm)
- Columna 14 : Precipitacion de 6 a 12 horas (mm)
- Columna 15 : Precipitacion de 12 a 18 horas (mm)
- Columna 16 : Precipitacion de 18 a 24 horas (mm)

Librerías…

```r
library(tseries)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
library(lubridate)
```

```
##
## Attaching package: 'lubridate'

## The following object is masked from 'package:base':
##
##     date
```

Leemos el dataset y, como solo nos interesa la fecha y la temperatura máxima nos quedamos con tan solo esos datos.

```r
datos = read.csv("5530E.csv", header = TRUE, sep=";")
datos = datos[,c("Fecha","Tmax")]
datos$Fecha = as.Date(datos$Fecha)
```

Veamos los valores NA…

```r
apply(datos, 2, function(atributo){sum(is.na(atributo))})
```

```
## Fecha  Tmax
##     0   124
```

Eliminamos las instancias(días) donde hay al menos algún valor NA de temperatura máxima

```r
datos = datos[complete.cases(datos),]
```

La serie que nos interesa es la temperatura máxima de cada uno de los meses, es decir, obtenemos la temperatura máxima de cada mes de cada año:

```r
# agrupamos por año y mes y tomamos el maximo de cada uno
datos = datos %>%
mutate(month = format(Fecha, "%m"), year = format(Fecha, "%Y")) %>%
group_by(year, month) %>%
summarise(total = max(Tmax))

serie = datos$total # aqui estan las temperaturas máximas de cada mes de todos los años
```

Obtenemos ahora la cantidad de datos a predecir y la serie temporal en sí

```r
Npred = 2 # cantidad de datos a predecir (temperaturas máximas de marzo y abril)
serie.ts = ts(serie, frequency = 12) # frequency set to 12 to set stationality each 12 months
plot(decompose(serie.ts))
```

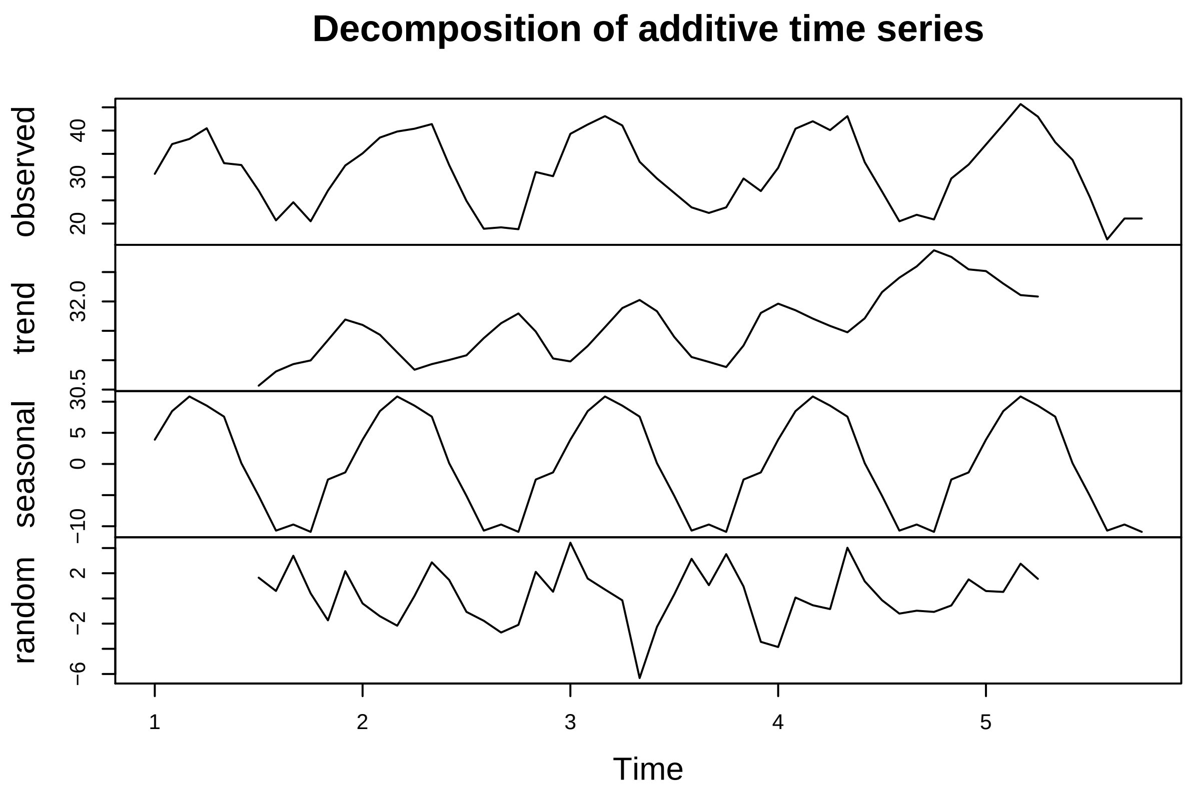

Observamos en la gráfica:
-los valores de la serie
-la tendencia calculada mediante filtros
-la estacionalidad repetida cada 12 instantes de tiempo -lo que queda de la serie al eliminar tendencia y estacionalidad

Como vemos, es posible que exista una alta varianza en los datos sin estacionalidad y tendencia, por lo que probamos a aplicar una transformación logarítmica para evitar problemas a la hora de tener en cuenta la estacionariedad, ya que sabemos que una serie con estacionariedad no varía ni en media ni en varianza.

```
serie.ts.log = log(serie.ts)
serie.log = log(serie)
plot(decompose(serie.ts.log))
```

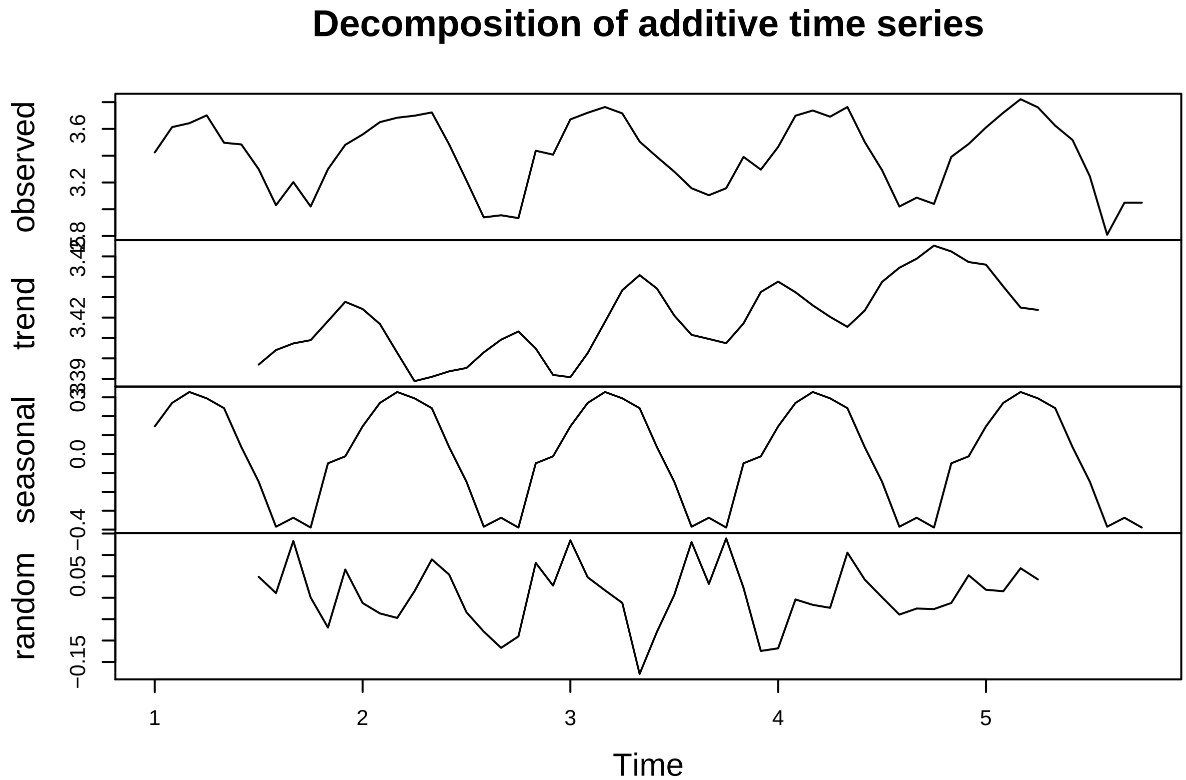

De forma ligera, la varianza disminuye a lo largo del tiempo, lo que producirá menores problemas a la hora de calcular la estacionariedad. Por simplicidad usare la variable serie como serie.log (con la transformación hecha)

```
serie = serie.log
```

Observamos como el atributo seasonal que nos da la función decompose consta de los mismos valores para cada año de todos los meses, lo cual nos dará la capacidad de calcular la estacionalidad para restársela a la serie.

```
decompose(serie.ts.log)$seasonal
```

```
##             Jan         Feb         Mar         Apr         May         Jun
## 1  0.14624562  0.27038082  0.32826498  0.29462730  0.24274200  0.03660037
## 2  0.14624562  0.27038082  0.32826498  0.29462730  0.24274200  0.03660037
## 3  0.14624562  0.27038082  0.32826498  0.29462730  0.24274200  0.03660037
## 4  0.14624562  0.27038082  0.32826498  0.29462730  0.24274200  0.03660037
## 5  0.14624562  0.27038082  0.32826498  0.29462730  0.24274200  0.03660037
##             Jul         Aug         Sep         Oct         Nov         Dec
## 1 -0.14645133 -0.38469232 -0.33717450 -0.38909044 -0.04904490 -0.01240760
## 2 -0.14645133 -0.38469232 -0.33717450 -0.38909044 -0.04904490 -0.01240760
## 3 -0.14645133 -0.38469232 -0.33717450 -0.38909044 -0.04904490 -0.01240760
## 4 -0.14645133 -0.38469232 -0.33717450 -0.38909044 -0.04904490 -0.01240760
## 5 -0.14645133 -0.38469232 -0.33717450 -0.38909044
```

Calculamos los instantes de tiempo de la serie para train y para test

```r
# para train
tiempo = 1:length(serie)
# para test
tiempoTs = (tiempo[length(tiempo)]+1):(tiempo[length(tiempo)]+Npred)
```

Representamos a continuación la serie que tenemos en este momento:

```r
plot.ts(serie,  xlim=c(1, tiempoTs[length(tiempoTs)]))
```

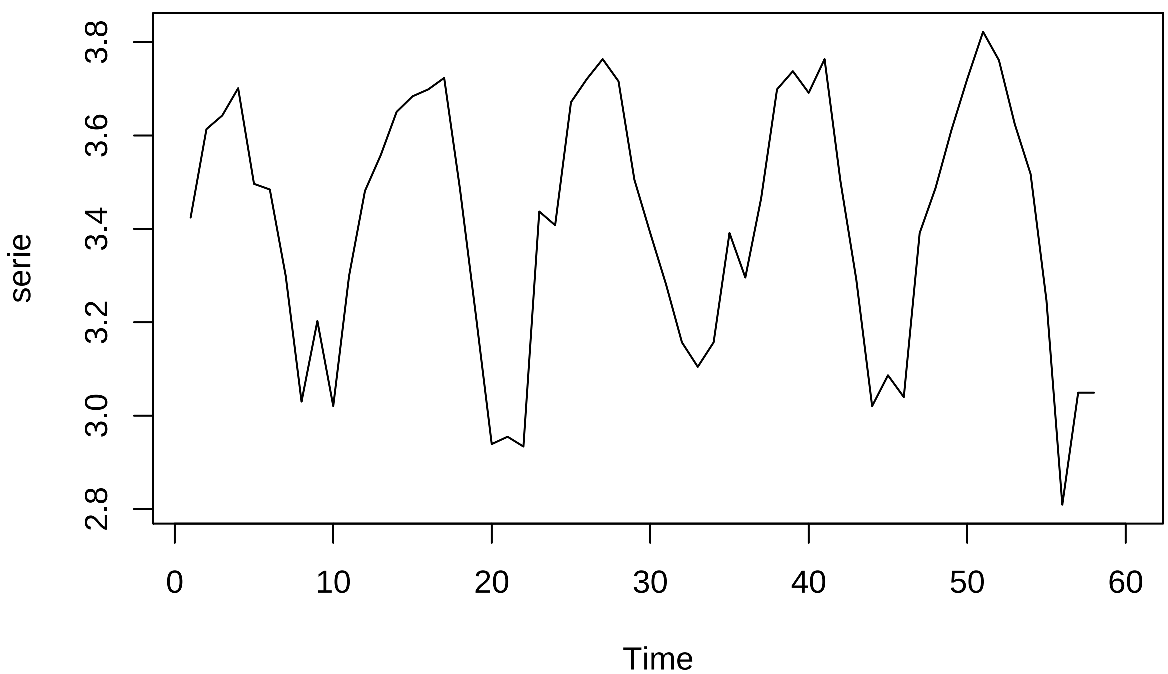

Modelamos la tendencia, la cual podemos aparentemente ajustarla de forma lineal, sabiendo que:
serie = parametroA * tiempo + parametroB
Con ayuda de la función lm calculamos dichos parámetros:

```r
parametros.H1 = lm(serie ~tiempo)
parametros.H1
```

```
##
## Call:
## lm(formula = serie ~ tiempo)
##
## Coefficients:
## (Intercept)       tiempo
##    3.451367    -0.001317
```

Tomamos Intercept como termino independiente (parametroB) y el otro como el que multiplica al tiempo para poder calcular la serie (parametroA). Para modelar la tendencia usamos la fórmula descrita antes:

```
# tendencia estimada para los datos de train
tendEstimadaTr =  parametros.H1$coefficients[1] + tiempo*parametros.H1$coefficients[2]
# tendencia estimada para las predicciones de test
tendEstimadaTs =  parametros.H1$coefficients[1] + tiempoTs*parametros.H1$coefficients[2]
```

Comprobamos visualmente si la tendencia se ajusta al modelo que tenemos de la serie temporal:

```
plot.ts(serie, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempo, tendEstimadaTr, col = "blue")
lines(tiempoTs, tendEstimadaTs, col = "green")
```

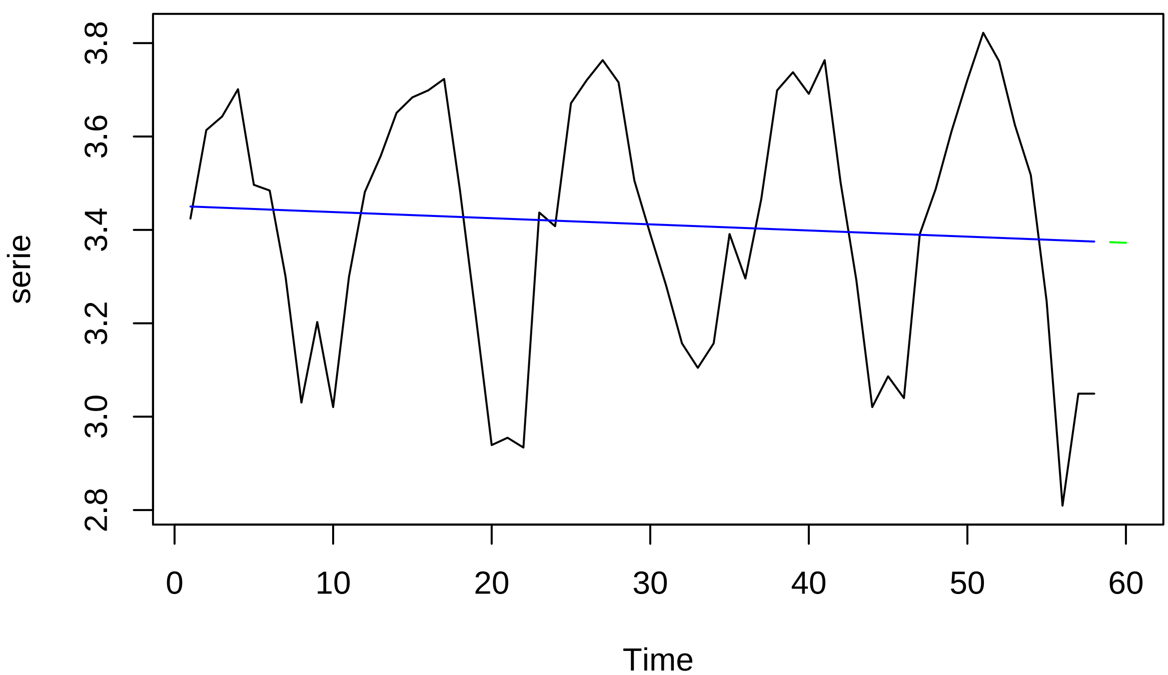

Validamos de forma estadística que el modelo lineal sea correcto, comprobando que los errores a lo largo de la serie se distribuyen mediante una distribución normal. Para ello aplicamos el test de Jarque-Bera:

```
JB = jarque.bera.test(parametros.H1$residuals)
JB
```

```
##
##  Jarque Bera Test
##
## data:  parametros.H1$residuals
## X-squared = 3.6086, df = 2, p-value = 0.1646
```

Podemos asumir, con una confianza del 95%, que no hay diferencia significativa de los datos de error con respecto a los de una distribución normal, debido a que el p-value es mayor que 0.05.

Procedemos por tanto a eliminar la tendencia de la serie actual:

```
serie.sinTend = serie - tendEstimadaTr
```

Comprobamos como queda la serie sin tendencia:

```
plot.ts(serie.sinTend, xlim=c(1, tiempoTs[length(tiempoTs)]))
```

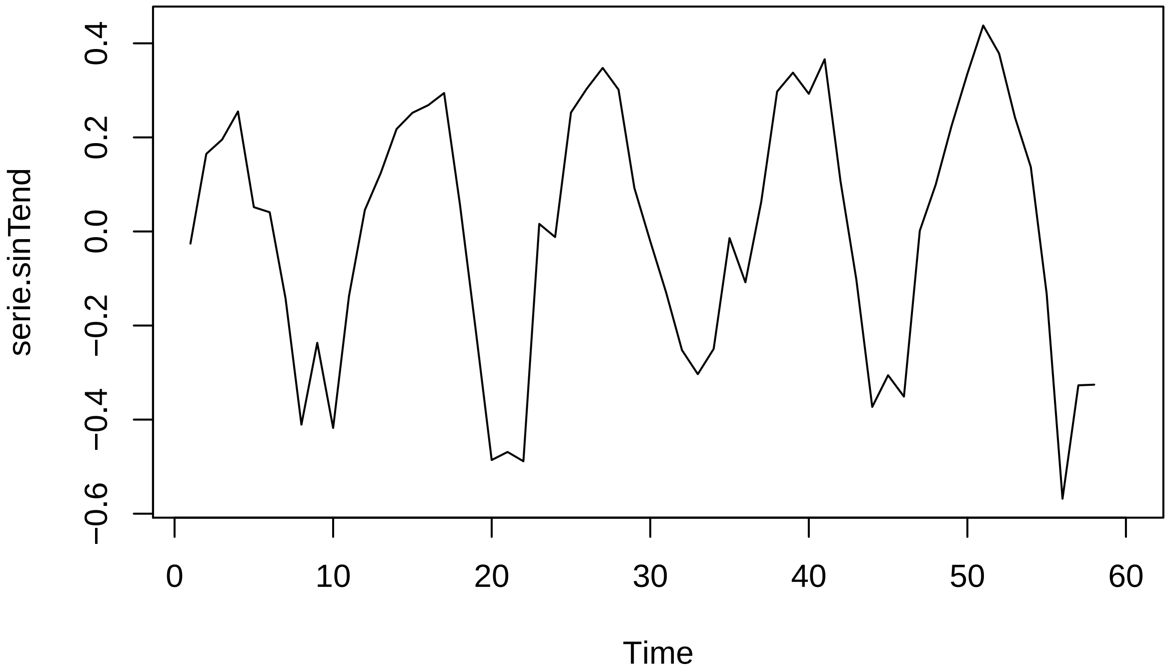

Como vemos, la serie sin tendencia prácticamente es la misma que con ella, ya que la pendiente del modelo lineal creado para el cálculo de ésta era ínfima.

Procedemos, una vez eliminada la tendencia, a deshacernos de la estacionalidad con ayuda de la función decompose.

```
k = 12 # aquí guardamos los datos estacionales
estacionalidad = decompose(serie.ts.log)$seasonal[1:k]
```

Eliminamos dicha estacionalidad a la serie.

```
serie.sinTend.sinEst = serie.sinTend - estacionalidad
```

```
## Warning in serie.sinTend - estacionalidad: longitud de objeto mayor no es
## múltiplo de la longitud de uno menor
```

Comprobamos como se queda la serie sin dicha estacionalidad

```r
plot.ts(serie.sinTend.sinEst, xlim=c(1, tiempoTs[length(tiempoTs)]))
```

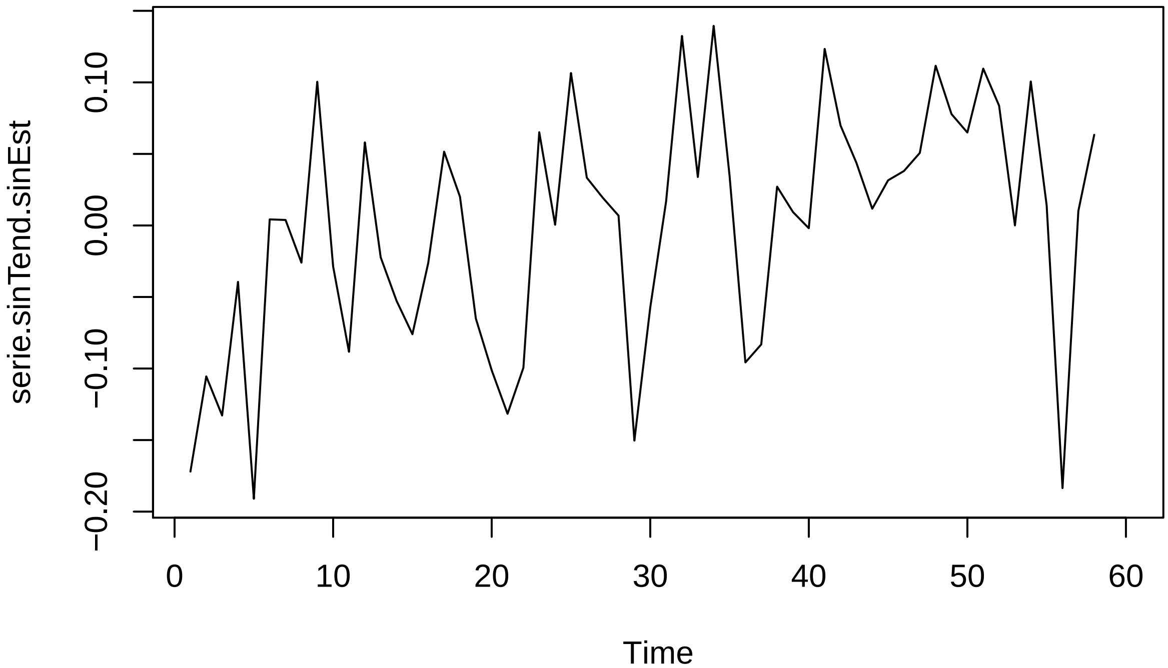

Ahora que tan solo nos queda la componente irregular tras haber eliminado las componentes de tendencia y estacionalidad, procedemos a comprobar si la serie es estacionaria o no mediante el test ACF.

```r
acf(serie.sinTend.sinEst)
```

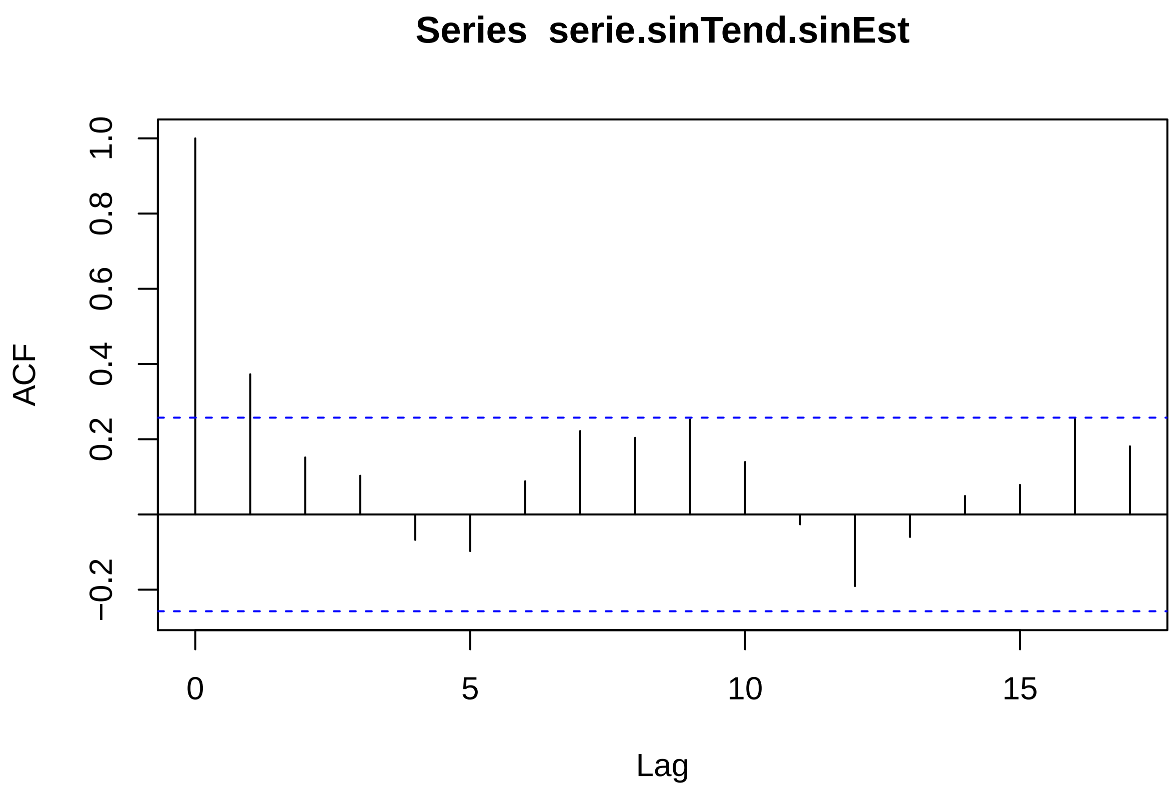

A priori parece ser, debido a la rapidez de bajada entre instantes de tiempo y a la estabilización en forma de ‘’olas”, que existe una clara estacionariedad. Aun así, probaré aplicar el test de Dickey-Fuller aumentado para asegurarnos de ello.

```
adf.test(serie.sinTend.sinEst)
```

```
## Warning in adf.test(serie.sinTend.sinEst): p-value smaller than printed p-
## value
```

```
##
##  Augmented Dickey-Fuller Test
##
## data:  serie.sinTend.sinEst
## Dickey-Fuller = -4.9184, Lag order = 3, p-value = 0.01
## alternative hypothesis: stationary
```

Al tomar como hipótesis nula que la serie es estacionaria y al ser el p-value inferior a 0.05, podemos asegurar con un 95% de probabilidad que la serie es estacionaria, por tanto la tomamos así. Debido a esto no será necesario realizar diferenciación para convertir la serie en estacionaria.

Observamos el acf parcial para ver como influyen de forma individual cada uno de los instantes de tiempo sobre el instante actual.

```
pacf(serie.sinTend.sinEst)
```

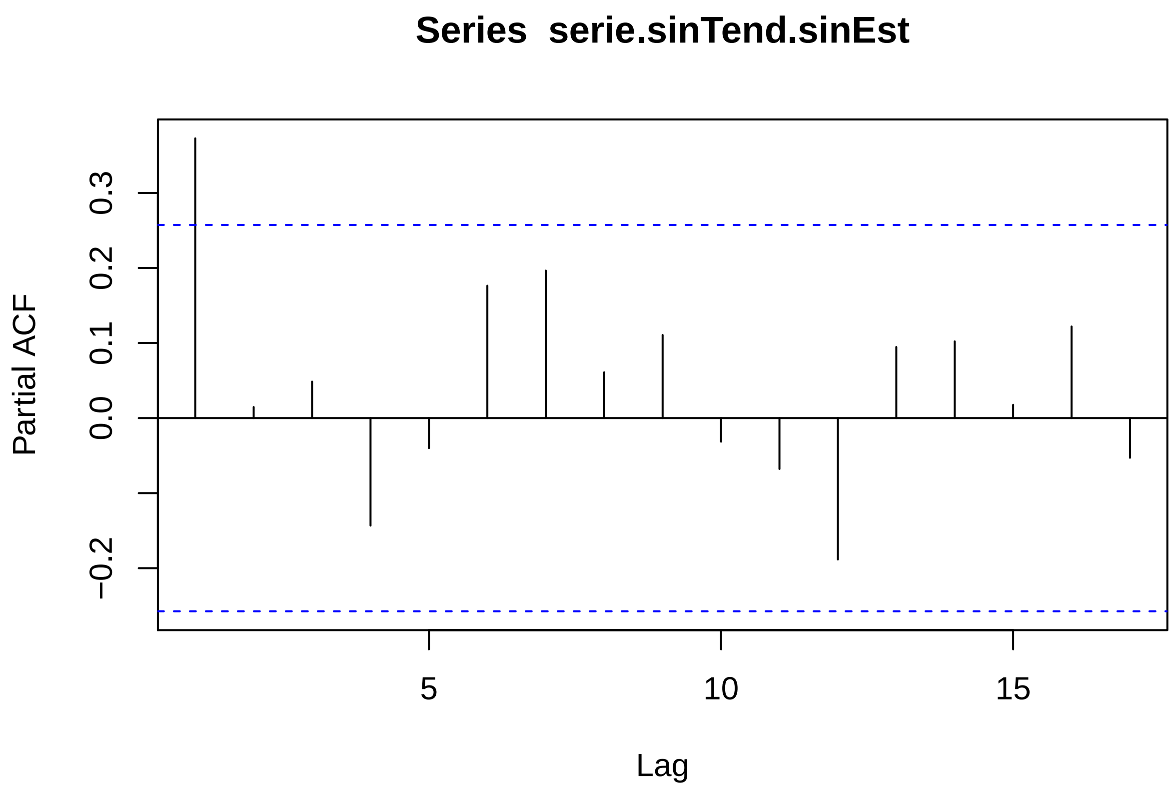

A la vista de las gráficas ofrecidas por ACF y PACF, me resulta de mayor claridad decidirme por un modelo autoregresivo en lugar de uno de medias móviles debido a que en ACF los valores de cada instante son más altos y sobrepasan los límites más que los de PACF, además de que se ve de forma mucho más clara esa estabilización en forma de ‘’olas” que he dicho anteriormente en la gráfica del ACF. Por ello mismo, deberíamos poder modelar la componente irregular de la serie con un modelo autoregresivo de orden 0 (fijándonos en la gráfica PACF), utilizando un modelo ARIMA con cero diferenciaciones. Entrenamos dicho modelo a continuación:

```
# coeficiente de autoregresión = 0, diferenciaciones = 0, coeficiente de medias moviles = 0
modelo = arima(serie.sinTend.sinEst, order = c(0,0,0))

# calculamos las predicciones
predicciones = predict(modelo, n.ahead = Npred)
valoresPredichos = predicciones$pred
valoresPredichos
```

```
## Time Series:
## Start = 59
## End = 60
## Frequency = 1
## [1] -0.001059526 -0.001059526
```

Observamos ahora de forma visual el modelo incluyendo la serie sin tendencia ni estacionalidad

```
plot.ts(serie.sinTend.sinEst, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempoTs,valoresPredichos, col="green")
```

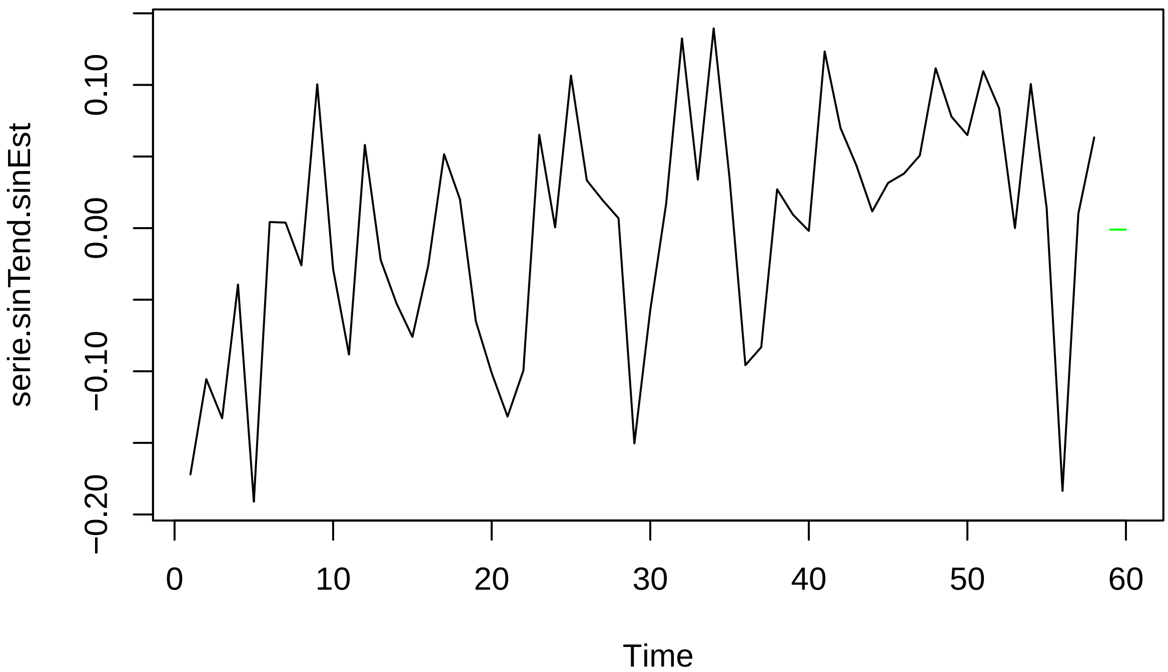

Parece ser que los resultados obtenidos no son buenamente fieles a lo esperado, quizás debido a la cercanía de los valores en los sucesivos instantes de tiempo en las gráficas ACF y PACF. Visto lo visto, puede decirse que nuestra serie es prácticamente ruido blanco debido a los resultados obtenidos como predicciones.
Finalmente probamos la validez de nuestro modelo (sus errores) mediante tests estadísticos. Aplicamos varios:

Test de Box-Pierce: comprobamos que los residuos que nos quedan son aleatorios:

```
Box.test(modelo$residuals)
```

```
##
##  Box-Pierce test
##
## data:  modelo$residuals
## X-squared = 8.0586, df = 1, p-value = 0.004529
```

Tras este test comprobamos que los errores obtenidos no son de forma aleatoria, por lo que el modelo arima creado no es correcto. Debido a esto, probaré el ajuste de un modelo de medias móviles de grado 1 (el grado determinado por la gráfica ACF) para comprobar su validez:

```
# coeficiente de autoregresión = 0, diferenciaciones = 0, coeficiente de medias moviles = 1
modelo = arima(serie.sinTend.sinEst, order = c(0,0,1))

# calculamos las predicciones
predicciones = predict(modelo, n.ahead = Npred)
valoresPredichos = predicciones$pred
valoresPredichos
```

```
## Time Series:
## Start = 59
```

```
## End = 60
## Frequency = 1
## [1]  0.011869071 -0.001802729
```

Observamos los valores predichos con el modelo de medias móviles con la serie sin tendencia ni estacionalidad:

```
plot.ts(serie.sinTend.sinEst, xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempoTs,valoresPredichos, col="green")
```

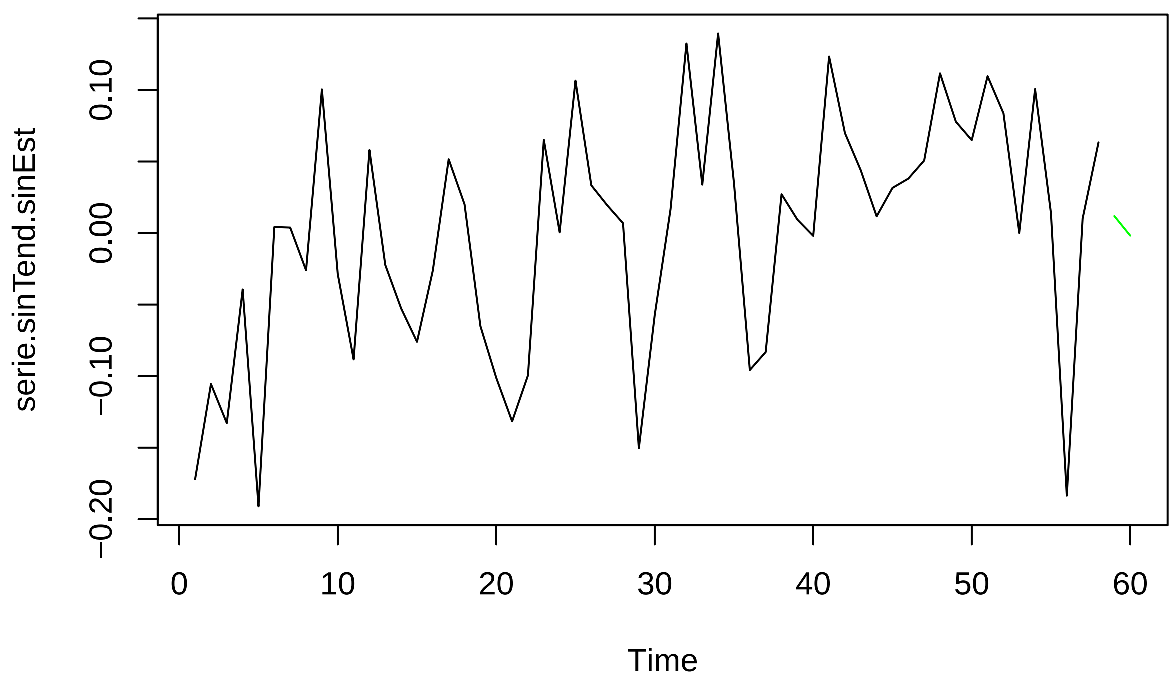

Aplicamos de nuevo el test de Box-Pierce para la comprobación de la aleatoriedad de los errores:

```
Box.test(modelo$residuals)
```

```
##
##  Box-Pierce test
##
## data:  modelo$residuals
## X-squared = 0.0086579, df = 1, p-value = 0.9259
```

Este valor de p-value nos dice con un 95% de confianza que los errores obtenidos por el modelo creado son aleatorios, por lo que el modelo queda validado por este test.

Continuamos con los tests de normalidad.

Jarque Bera: vemos si los residuos, aunque aleatorios, son normales (media cero y desviación típica la que sea).

```
jarque.bera.test(modelo$residuals)
```

```
##
##  Jarque Bera Test
```

```
##
## data:  modelo$residuals
## X-squared = 1.3191, df = 2, p-value = 0.5171
```

Saphiro-Wilk: mismo cometido que Jarque Bera

```r
shapiro.test(modelo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  modelo$residuals
## W = 0.9788, p-value = 0.4025
```

Asumimos tras la ejecución de ambos tests que los residuos siguen una distribuición normal debido a los p-values obtenidos, ya que la hipótesis nula propone que los datos no siguen una distribución normal.

A continuación obtenemos un histograma y función de densidad para obtener resultados gráficos de confirmación.

```r
hist(modelo$residuals, col="blue", prob=T,ylim=c(0,20), xlim=c(-0.2,0.2))
lines(density(modelo$residuals))
```

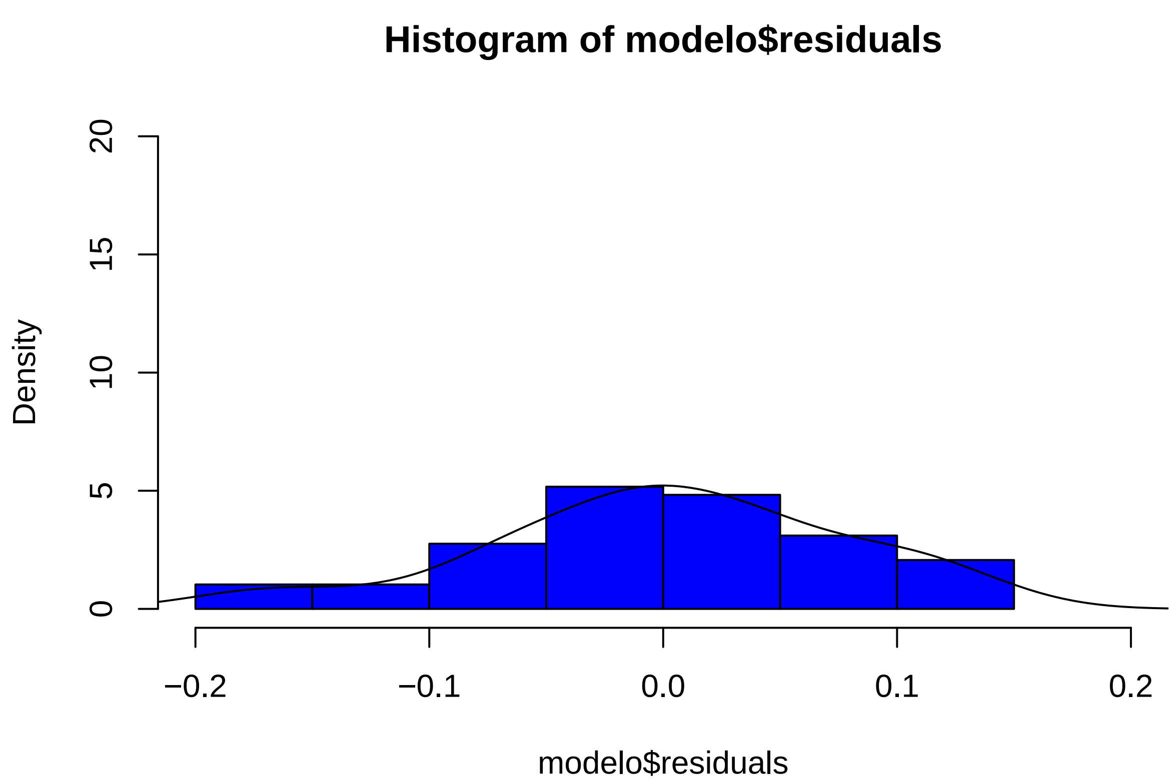

Con estas comprobaciones el modelo queda validado, ya que los errores que nos dan son aleatorios que provienen de una distribución normal. A continuación hemos de deshacer los cambios para obtener los predicciones reales:

```r
estacionalidades = c(estacionalidad[11], estacionalidad[12])

# Incluimos la estacionalidad
```

```r
valoresPredichos.Est = valoresPredichos + estacionalidades

# Incluimos la tendencia
valoresPredichos.Est.Tend = valoresPredichos.Est + tendEstimadaTs

# Transformación de los logaritmos
valoresPredichos.Est.Tend.exp = exp(valoresPredichos.Est.Tend)

# usamos exp(serie) por haber hecho al principio serie = log(serie)
plot.ts(exp(serie),xlim=c(1, tiempoTs[length(tiempoTs)]))
lines(tiempoTs, valoresPredichos.Est.Tend.exp, col = "green")
```

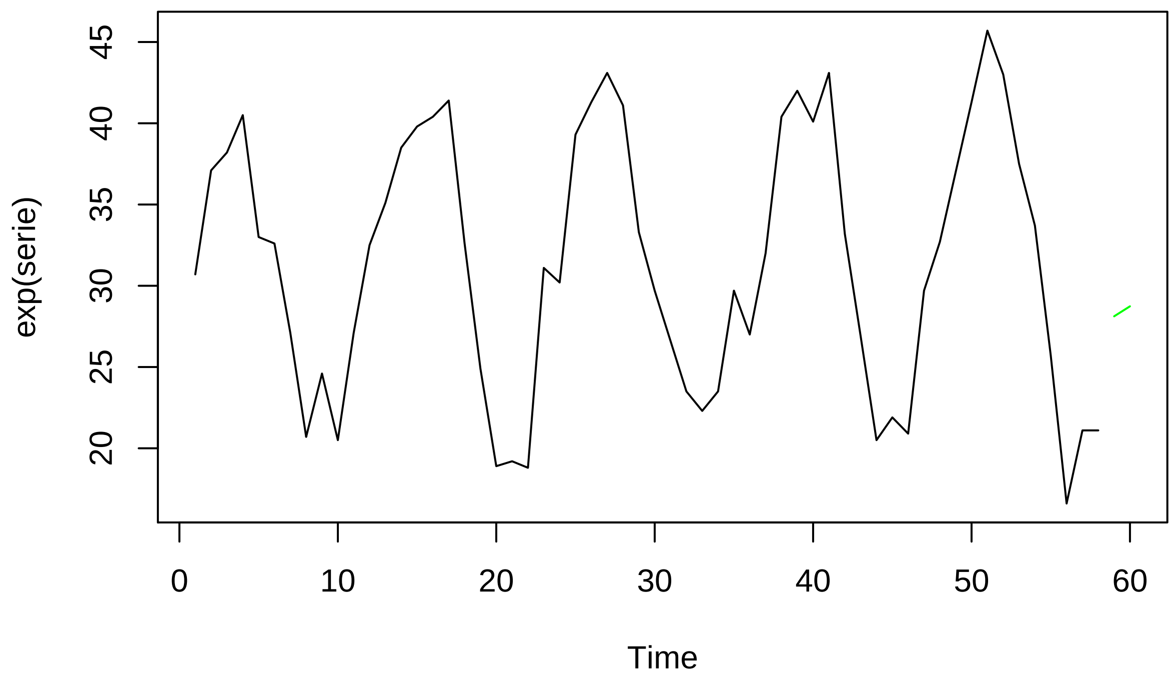

Finalmente podemos observar en la gráfica los valores de temperatura máxima obtenidos para los meses de Marzo y Abril de 2018, los cuales se corresponden respectivamente con los valores:

```r
valoresPredichos.Est.Tend.exp
```

```
## Time Series:
## Start = 59
## End = 60
## Frequency = 1
## [1] 28.12089 28.73632
```